Laboratorium PAiMSI 10
Najdłuższy Wspólny Podciąg

Witold Zimnicki - nr 200465

25 maja 2014

1. Cel ćwiczenia:

Celem ćwiczenia było zapoznanie się z algorytmem **NWP** (Najdłuższy Wspólny Podciąg) oraz jego zaimplementowanie w taki sposób, aby możliwe było zaprezentowanie wyników udowadniających jego poprawne działanie.

2. Najdłuższy Wspólny Podciąg:

- Zadaniem algorytmu **NWP** jest wyszukanie najdłuższego wspólnego łańcucha znaków w dwóch ciągach wyrazów. Unikatowość swoją zawdzięcza temu, że elementy łańcucha nie muszą leżeć obok siebie. Wykorzystywany może być do wykrywania plagiatów lub do różnego rodzaju systemów kontroli wersji.

- Problem NWP dwóch ciągów A i B o długościach odpowiednio n i m może być rozwiązany za pomocą metody programowania dynamicznego. Algorytm ten ma złożoność obliczeniową rzędu $O(n * m)$, gdzie n oraz m to długości ciągów A i B. Algorytm ten tworzy tablicę dwuwymiarową C (n na m) taką, że wartość C[i][j] jest długością NWP podciągów A[1..i] i B[1..j]. A więc po zakończeniu wypełniania tablicy C komórka C[n][m] będzie zawierała wartość będąca długością NWP oryginalnych ciągów wejściowych A i B.

Odtworzenie najdłuższego podciągu:

Polega ono na utworzeniu macierzy o wymiarach n+1 x m+1 (n i m to długości ciągów A i B). Pierwsza kolumna oraz wiersz są zerami. Następnie wypełniamy macierz aż do końca jednym schematem:

1. Jeśli znak kolejnego wiersza i kolumny są takie same - inkrementowana jest wartość na ukos z lewej strony.
2. Jeśli znaki kolejnego wiersza i kolumny nie są takie same - w zależności od tego która jest większa, przypisywana jest wartość sąsiada na górze, lub po lewej.

Sprawdzenie zawartości najdłuższego wspólnego podciągu:

Aby dowiedzieć się jaki to podciąg należy 'przejść' z ostatniej komórki macierzy do komórki początkowej według następującego algorytmu:

1. jeśli któraś komórka sąsiednia do tej w której jesteśmy (z lewej strony lub u góry) ma wartość identyczną, to przechodzimy do niej.
2. jeśli jesteśmy w komórce zerowej to zakończ.
3. jeśli nie ma takiej, do ciągu odpowiedzi dopisujemy na początek literę odpowiadającą tej komórce a następnie idziemy do komórki o wartości mniejszej o 1 (po skosie do góry i w lewo).
4. jeśli nie jesteśmy w komórce [0][0] to przeskocz do punktu 1. w przeciwnym wypadku Zakończ.

W związku z tym, że w każdym kolejnym kroku można iść zarówno w lewo jak i do góry, można uzyskać dwa, lub więcej podciągów.

3. Wyniki działania:

- **Wariant z jednym możliwym najdłuższym wspólnym podciągiem:**

  Działanie zostało sprawdzone na przykładowych ciągach znaków: "***komputer*** óraz "***komputerami***". Ich najdłuższy wspólny podciąg to "**komputer**". Sprawdzimy zatem ich działanie zaimplementowanego w ćwiczeniu algorytmu:

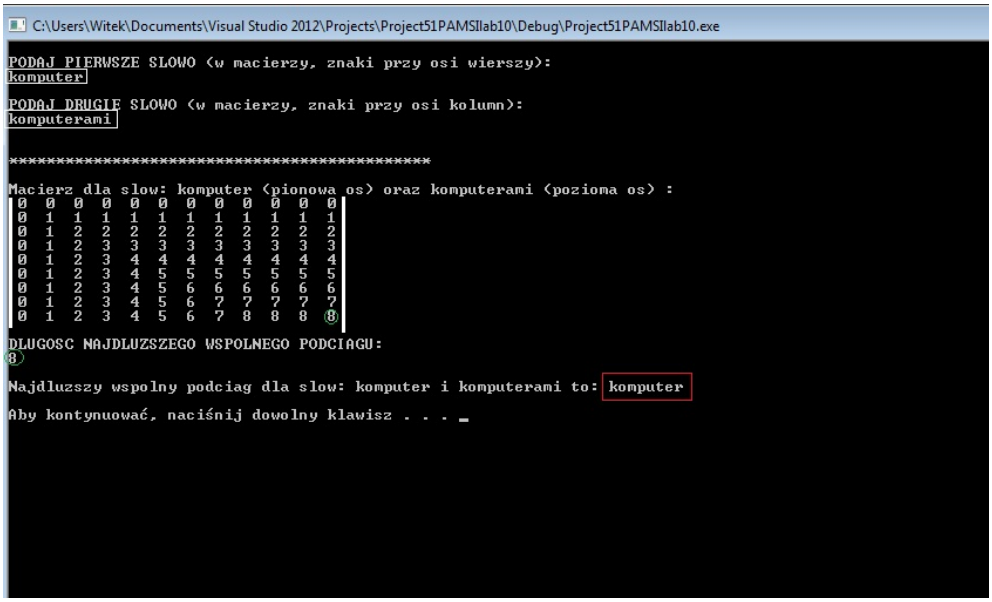

Rysunek 1: Wariant 1

- **Wariant z dwoma możliwymi najdłuższymi wspólnymi podciągami (gdy idziemy od ostatniego elementu w górę, lub w lewo:**

  Działanie zostało sprawdzone na przykładowych ciągach znaków: ***giggiiggg*** oraz ***igigi***. Ich najdłuższy wspólny podciąg to **igig** oraz **gigi**. Sprawdzimy zatem ich działanie zaimplementowanego w ćwiczeniu algorytmu:

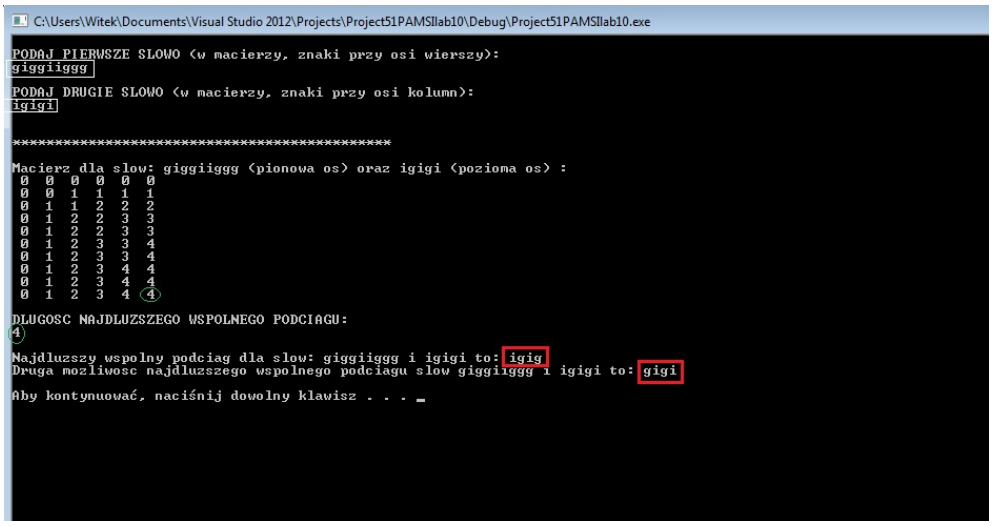

Rysunek 2: Wariant 2

- **Wariant z brakiem wspólnego podciągu:**

  Działanie zostało sprawdzone na przykładowych ciągach znaków: ***abcdef*** oraz ***ghijkl***. Sprawdzimy działanie zaimplementowanego w ćwiczeniu algorytmu:

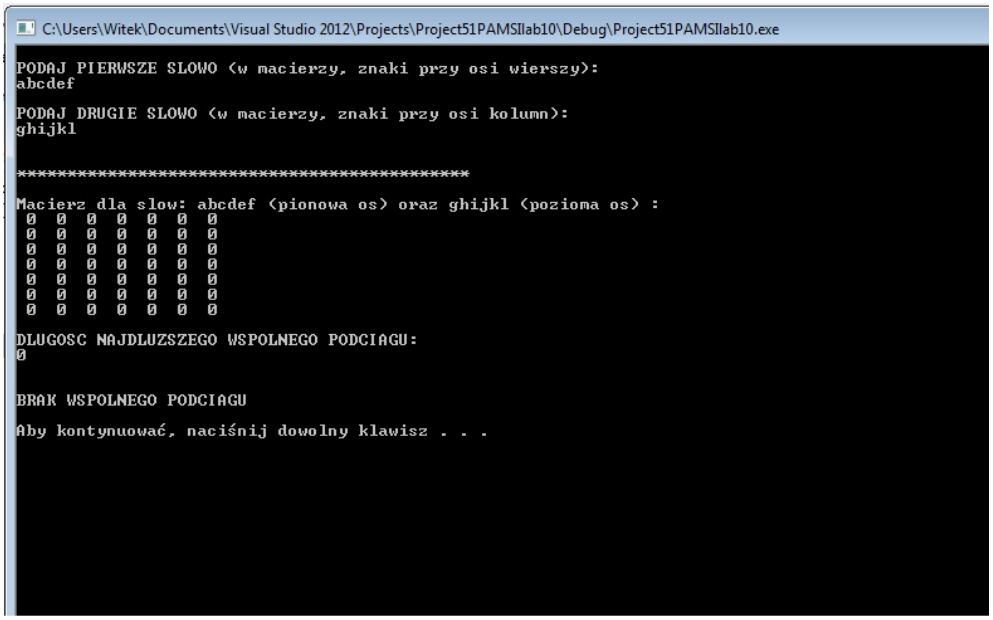

Rysunek 3: Wariant 3

4. Wnioski:

- Wyniki testu potwierdzają poprawność działania zaimplementowanych funkcji **NWP**.

- Ćwiczenie pokazuje, że algorytm NWP może być przydatny w kontrolowaniu wersji dokumentów, książek czy też wykrywaniu plagiatów.

- Przy dużych rozmiarach ciągów uwidacznia się stosunkowo duża złożoność czasowa algorytmu $O(n*m)$, gdzie n i m to długości zadanych ciągów znaków .

- Algorytm wyszukuje wspólny najdłuższy podciąg, nawet jeśli elementy ciągów zadanych nie leżą obok siebie. Nie wolno go zatem mylić z algorytmem *najdłuższego wspólnego podłańcucha*.